Alfabetização no Brasil - relatório consolidado

Atualização de 01/11/2026. Este documento consolida a interpretação metodológica e os experimentos posteriores à entrega acadêmica v1. A v1 permanece congelada. O candidato enriquecido não substituiu o modelo final da v1.

Resultado e decisão

O modelo estima o risco de não alfabetização associado ao contexto municipal de cada aluno. A granularidade do alvo é individual; os atributos disponíveis são municipais. Assim, alunos de um mesmo município recebem a mesma probabilidade. A interpretação considera a granularidade disponível e suas limitações. O desempenho é comparado com a prevalência da classe positiva e com baselines global e estadual.

O candidato prioritário para evolução é a regressão logística com o bloco de rendimento escolar de 2022: reprovação e abandono nos anos iniciais e no 2º ano. Com C=1, sua AP média foi 0,52735, frente a 0,51990 da referência e 0,51088 do baseline por UF. A combinação com distorção não acrescentou ganho na métrica principal. A comparação curta de regularização posteriormente obteve AP média de 0,52765 com C=0,01 nesse candidato, um acréscimo pequeno que não justifica substituir a versão congelada. Não há confirmação independente de superioridade em uma nova safra.

Comparação com prevalência e baselines

A classe positiva é **não alfabetizado**. No treino, são 393.076 alunos nessa classe, em 968.939 avaliações válidas, resultando em prevalência de **40,57%**. As contagens abaixo devem ser lidas no recorte de alunos elegíveis, sem pesos amostrais do INEP.

Todos os candidatos e baselines foram comparados nos mesmos três folds de municípios, estratificados por UF. Os modelos logísticos da tabela a seguir usam C=1; a busca posterior de regularização é apresentada separadamente. Para cada fold, o baseline global recebe a prevalência dos municípios de ajuste. O baseline por UF recebe a prevalência estadual calculada apenas nos municípios de ajuste. Nenhum alvo do fold de avaliação é usado para criar suas previsões.

Configuração	AP média dos folds	Δ AP versus global	Δ AP versus UF	Brier OOF
Probabilidade global	0.40509	+0.00000	-0.10578	0.24114
Probabilidade por UF	0.51088	+0.10578	+0.00000	0.22938
Logística de referência	0.51990	+0.11481	+0.00903	0.22922
Referência + distorção	0.52590	+0.12081	+0.01502	0.22731
Referência + rendimento	0.52735	+0.12226	+0.01647	0.22756
Referência + ambos	0.52640	+0.12131	+0.01553	0.22741

A AP do score constante em cada fold é exatamente a prevalência observada naquele fold. A média dessas prevalências foi **0,40509**. Ela difere da prevalência geral do treino, **0,40568**, porque a média dos três folds dá o mesmo peso a cada fold, enquanto a taxa geral pondera a quantidade de alunos.

O candidato com rendimento supera o baseline global em **0,12226 ponto de AP** e o baseline por UF em **0,01647 ponto de AP**, na média dos folds. A razão entre sua AP e a do baseline global é 1,302. Essa razão

não significa acurácia de 130%, precisão de 52,7% em um limiar ou melhoria garantida de resultados educacionais.

O baseline por UF já alcança boa parte da discriminação observada. Por isso, a comparação com ele é mais exigente e informativa que apenas comparar com a prevalência global. O acréscimo do rendimento à logística de referência é de 0,00744 na AP média, consistente nos três folds, mas modesto.

AP maior é melhor. Brier menor é melhor e mede o erro quadrático das probabilidades. AP é average precision, não a área trapezoidal da curva precisão-recall. As métricas OOF agrupadas são calculadas reunindo scores de ajustes distintos e não são iguais à média das métricas por fold. O baseline global varia ligeiramente entre folds; sua AP OOF agrupada pode, portanto, diferir da prevalência, embora dentro de cada fold ela seja exatamente igual. A comparação principal usa a média pareada nos mesmos folds.

Estrutura, origem e alvo

O backup da Fase 2 contém 1.840.277 registros de alunos de 2024, da rede municipal e do 2º ano. A auditoria manteve 1.610.754 avaliações válidas em 5.450 municípios e 36.920 grupos escolares. Registros sem avaliação válida foram excluídos, em vez de tratados como não alfabetizados. O alvo foi recodificado como 1 - alfabetizado.

A Gold original contém agregados municipais e estaduais. Os resultados individuais foram recuperados da Bronze e passaram pelos filtros e validações da preparação analítica. Não se afirma que esses rótulos já existissem na Gold agregada. A rastreabilidade preserva essa adaptação. O enunciado da Fase 2 não fixa uma única granularidade para a Gold; a Fase 3 estabelece classificação por aluno e permite enriquecimento externo.

A tabela lógica individual possui chave pseudonimizada do aluno, grupo escolar pseudonimizado, código IBGE do município, ano, resultado e peso amostral de origem. O código municipal conecta os indicadores de contexto. O peso amostral é preservado como metadado, mas não foi empregado na função de perda ou nas métricas aqui reportadas.

Como o X é constante por município, os ajustes usam duas linhas por município, uma para cada classe, com pesos iguais às contagens correspondentes. Esse é um recurso computacional equivalente à classificação das observações individuais sob essas features. Não é regressão de taxa municipal e não cria informação individual nova. As contagens e proporções de alfabetização não entram como preditores.

Contrato proposto para uma Gold individual

É possível manter os agregados da Fase 2 e acrescentar um dataset individual para modelagem, sem alterar o alvo ou reconstruir toda a arquitetura. A implementação atual já dispõe da tabela individual e do contexto em banco analítico local. Isso não representa publicação de uma nova Gold em cloud nem reexecução do pipeline da Fase 2.

Grupo	Campos e regras
Chave	aluno_chave pseudonimizada; unicidade definida com a referência temporal
Referência	ano_avaliacao, id_municipio IBGE de sete dígitos e escola_grupo pseudonimizada
Alvo	alfabetizado em {0,1}; nao_alfabetizado derivado como 1 - alfabetizado
Elegibilidade	Somente avaliações que passam nos filtros de presença, preenchimento e resultado válido
Contexto atual	População/densidade 2022; PIB por habitante e composição econômica 2021; UF
Contexto candidato	Reprovação e abandono, anos iniciais e 2º ano, 2022

Grupo	Campos e regras
Proveniência	Fonte, ano de referência, data de publicação, extração, edição e hash em manifesto
Divisão	Uma atribuição de conjunto e fold por município, controlada à parte dos preditores

Os nomes finais das colunas, as unidades e a edição das fontes devem constar no dicionário. Fontes externas entram tratadas e validadas, com chave municipal única por recorte de ano, rede e localização. Ausência não vira zero automaticamente. Não incluir presença, proficiência, ranking ou resultado contemporâneo como atributos de entrada.

Prevenção de vazamento e validação

A divisão fixa preserva todos os alunos de um município no mesmo conjunto: 968.939 alunos no treino, 320.639 na validação e 321.176 no teste. Nos experimentos posteriores usamos somente o treino. Os mesmos três folds municipais foram mantidos para todas as comparações.

Mediana, indicador de ausência, padronização e one-hot são ajustados apenas nos municípios de ajuste de cada fold. A escala considera municípios com peso igual; a função de perda considera contagens de alunos. O baseline por UF também é estimado só no fold de ajuste. Nenhum identificador ou contagem do alvo entra no vetor de preditores.

As comparações iniciais de blocos empregaram regressão logística L2, C=1, solver lbfgs, max_iter=3000, tol=1e-8 e semente 42. Os três controles do experimento combinado reproduziram o experimento anterior. Em seguida, uma grade curta variou C, mantendo os demais parâmetros e os folds fixos, conforme a seção de regularização. Todos os ajustes dessas rodadas convergiram sem avisos.

Os indicadores externos são anteriores à avaliação de 2024 por referência e publicação documentada. Downloads atuais não garantem identidade com os bytes publicados em 2023; não se apresenta esta análise como backtest com snapshot histórico certificado.

Experimentos e limites da evidência

INSE, distorção, rendimento, VAAT e renda estadual da PNAD foram testados separadamente. INSE oscilou e não melhorou a média. VAAT e PNAD não demonstraram ganho relevante na configuração testada. Rendimento e distorção melhoraram a referência nos três folds. A combinação atingiu AP média de 0,52640 e ficou abaixo do rendimento isolado em dois folds.

No experimento de blocos com C=1, o candidato com rendimento melhorou a AP frente à referência em 21 das 25 UFs e piorou em quatro. Não há melhora uniforme. Distorção apresentou Brier e log loss ligeiramente melhores que rendimento, embora rendimento tenha maior AP média. A prioridade segue a métrica principal declarada, sem afirmar superioridade universal.

Os intervalos anteriores usam bootstrap municipal estratificado por UF com previsões OOF fixas. Não incluem refazer ajustes e escolhas de atributos; não corrigem comparações múltiplas. Não se deve tratar as rodadas sucessivas de desenvolvimento nos mesmos folds como confirmações independentes.

Comparação curta de regularização

Foi realizada uma busca manual e pré-definida em C = 0,01; 0,1; 1 e 10, separadamente para a logística de referência e o candidato com rendimento escolar. São 24 ajustes: dois blocos, quatro valores de C e três folds municipais do treino, com 3.267 municípios e 968.939 alunos. A métrica principal é a média simples de AP nos folds; não houve consulta à validação externa ou ao teste para escolher C.

Em todos os ajustes, mantiveram-se regularização L2, solver lbfgs, max_iter=3000, tol=1e-8, semente 42 e pesos de frequência iguais às contagens de alunos. Menor C implica regularização mais forte. Como os pesos não foram normalizados, a magnitude de C não deve ser comparada diretamente a experimentos com outra escala de pesos.

A função de treinamento passou a combinar os padrões com os parâmetros fornecidos, dando precedência aos valores informados e eliminando argumentos duplicados. Imputação, escala e encoding continuam ajustados somente nos municípios de ajuste de cada fold. O cálculo de AP também usa as contagens de alunos; não é uma média sobre as duas linhas comprimidas sem ponderação.

C	AP média referência	Delta vs C=1	AP média com rendimento	Delta vs C=1
0,01	0,5200306	0,0001273	0,5276477	0,0003013
0,1	0,5197889	-0,0001144	0,5273749	0,0000286
1	0,5199033	0,0000000	0,5273463	0,0000000
10	0,5198896	-0,0000137	0,5273829	0,0000365

C=0,01 teve a maior AP média nos dois blocos. O ganho sobre C=1 foi de apenas **0,0001273** na referência e **0,0003013** com rendimento, com melhora em dois dos três folds de cada bloco. No candidato com rendimento, o desvio da AP entre folds foi 0,01519 em C=0,01 e 0,01449 em C=1. Essa variação não é um intervalo de confiança, mas ajuda a dimensionar o pequeno ganho observado.

Na AP OOF agrupada, a referência passou de 0,5155167 para 0,5154084; o candidato com rendimento passou de 0,5256989 para 0,5256922. Portanto, a maior média de AP entre folds não correspondeu a uma melhora da AP OOF agrupada. As duas medidas agregam os resultados de formas diferentes e não devem ser confundidas.

O Brier médio dos folds do candidato com rendimento caiu de 0,2270647 para 0,2268998. O gap entre AP média de ajuste e de holdout caiu de 0,0140237 para 0,0136326. São diferenças pequenas: o gap é apenas um diagnóstico descritivo, não uma curva de aprendizagem nem prova de ausência de overfitting.

Os controles C=1 reproduziram as APs da comparação anterior. Os 24 ajustes convergiram sem avisos, e oito testes automatizados passaram, incluindo sobrescrita de parâmetros e os contratos existentes. Os hashes dos modelos finais, do protocolo e dos resultados históricos de teste permaneceram iguais.

A escolha de C=0,01 é exploratória, feita nos mesmos folds já usados no desenvolvimento. **A configuração C=1 e o artefato final da v1 foram preservados.** O pequeno ganho não sustenta uma afirmação de superioridade populacional e não gerou nova avaliação de teste. Resultados completos, métricas por UF, protocolo e previsões OOF estão em reports/regularizacao/.

Resultado histórico da v1

A v1, com a logística contextual anterior aos novos indicadores, foi avaliada uma vez no teste: **AP 0,53556**, ROC AUC 0,64336, precisão 0,58963 e recall 0,27115 no limiar comparativo 0,50. Esses números são históricos e pertencem a outro conjunto e configuração. Não representam o desempenho final do candidato com rendimento e não devem ser comparados diretamente com sua AP de CV para alegar melhora ou piora.

O teste v1 já foi observado. Uma versão escolhida após essas explorações requer nova safra temporal ou nova amostra externa para confirmação independente. Nenhuma nova previsão no teste foi calculada nesta consolidação. A entrega v1 permanece preservada.

Insights e ações possíveis

Evidência	Aplicação possível	Limite
Há diferenças territoriais capturadas pelo baseline por UF	Estruturar diagnósticos estaduais e comparar municípios dentro de cada UF	UF não identifica mecanismo causal
Rendimento anterior acrescentou discriminação	Usar reprovação e abandono como dimensões para investigação das redes	Não prova que reduzir esses indicadores cause a melhora prevista
Todos os alunos do município compartilham o score	Apoiar triagem de contextos municipais para análise humana	Não indicar uma criança específica para intervenção com base apenas nesse score
Taxas pequenas são instáveis em municípios com poucos alunos	Mostrar denominadores e considerar incerteza no acompanhamento	Evitar ordenações rígidas baseadas em diferenças pequenas
Combinar blocos não trouxe ganho adicional	Priorizar o bloco de rendimento no próximo candidato e conservar uma solução simples	Resultado restrito à configuração e à base observada

Nenhum limiar operacional ou capacidade real de atendimento foi escolhido. Recomendações educacionais dependem de avaliação pedagógica local. Os scores são associações de contexto, sem causalidade e sem previsão temporal comprovada.

Reprodução e arquivos

Na raiz do repositório, execute python -m src.evaluation.baselines --output work/baselines_novos, em ambiente com as dependências de requirements.txt. O módulo lê data/processed/dados_treino_oof.json, contendo agregados municipais, contagens e previsões OOF, e recalcula os dois baselines. Não carrega modelos, não acessa microdados individuais e não consulta validação ou teste. comparacao_baselines.json registra métricas por fold, resumo, prevalência e hash da entrada. metricas_baselines_por_uf.json registra os resultados por estado. O dataset distribuído não contém identificadores individuais ou escolares.

Para repetir a busca curta, execute python -m src.modeling.regularization --output work/regularizacao_nova, com um diretório de saída novo. O comando usa os folds de treino e verifica a integridade dos artefatos congelados. A configuração efetiva, as métricas e os hashes estão em reports/regularizacao/protocolo.json e resultados.json.

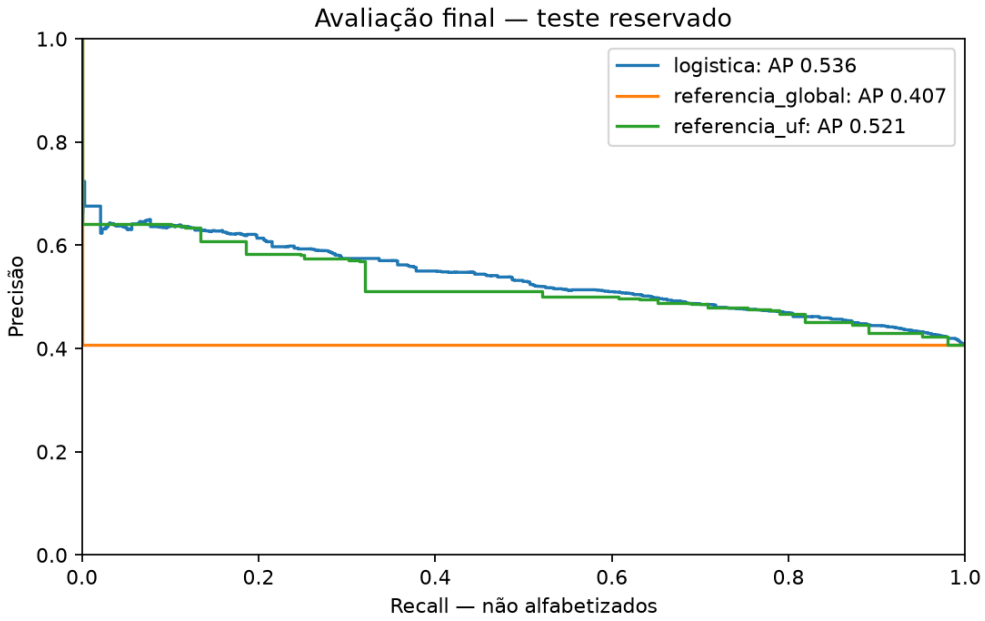
Os experimentos originais, a interpretação SHAP, os perfis exploratórios e a avaliação histórica permanecem documentados na entrega v1 e nos relatórios de validação cruzada, combinação e regularização. Esta atualização complementa essas evidências e não transforma os experimentos em um novo resultado final de teste.

Conclusão

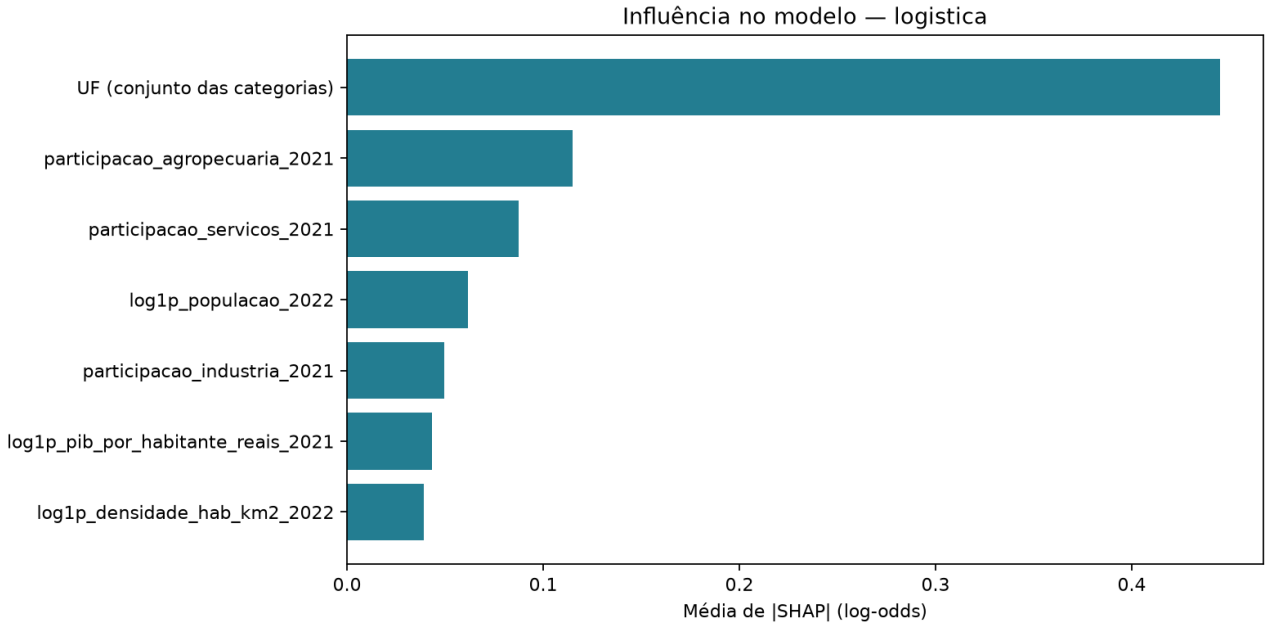
A classificação individual usa atributos municipais e, por isso, produz uma estimativa de risco contextual. A separação por município e o ajuste das transformações dentro dos folds reduzem o risco de vazamento entre os grupos de avaliação. O desempenho mostra ganho frente à prevalência e um ganho menor frente ao baseline por UF. Os indicadores de rendimento escolar constituem um candidato à evolução; a busca curta de regularização mostrou ganhos marginais e não motivou substituir a v1. A confirmação da evolução requer uma nova amostra independente.

Evidências visuais da avaliação histórica v1

As figuras desta seção pertencem à versão v1 congelada. Não são uma avaliação final do candidato com rendimento escolar. A curva precisão-recall resume o teste histórico; SHAP descreve associações do modelo e não efeitos causais.



Curva precisão-recall da avaliação histórica, sem novo cálculo de teste.



Importância SHAP da logística contextual v1. A UF concentra parte importante da informação territorial.

Fontes e documentos de apoio

Enunciados das Fases 2 e 3

Documentos fornecidos no curso; Fase 3, p. 2-5, define classificação individual, integração com Gold, enriquecimento e prevenção de vazamento.

Dados de origem

Backup auditado da Fase 2; manifestos e dicionários estão em data/source e data/gold_fase2.

IBGE

População e densidade de 2022; PIB e composição econômica de 2021. Referências e hashes nos manifestos de fontes.

INEP

Taxas municipais de distorção e rendimento de 2022 e INSE de 2021. Rede municipal, localização total, código IBGE para o vínculo.

FUNDEB e PNAD

VAAT de 2023, publicação de 28/08/2023, e renda domiciliar por UF de 2022. Experimentos não indicaram ganho relevante na configuração testada.

Reprodução

README.md e requirements.txt. Blocos: src/modeling/enrichment.py. Baselines: src/evaluation/baselines.py. Regularização: src/modeling/regularization.py. Resultados completos e protocolos estão nas subpastas de reports.

Endereços oficiais

https://www.gov.br/inep/pt-br/acesso-a-informacao/dados-abertos/indicadores-educacionais

https://www.gov.br/fnde/pt-br/acesso-a-informacao/acoes-e-programas/financiamento/fundeb/2023

https://www.ibge.gov.br/biblioteca/visualizacao/periodicos/3100/rdpc_2022.pdf